

## Informe Técnico

# Predicción de gasto en clientes e-commerce

**Nombre:** Carolina Tapia Bahamonde **Curso:** Ciencia de Datos **Fecha:** 19-03-2026

---

## 2. Descripción del dataset

El dataset utilizado contiene información de clientes de e-commerce, incluyendo variables relacionadas con comportamiento de compra, características demográficas y transacciones.

Se identificaron las siguientes características relevantes:

- Variables numéricas: precio, cantidad, edad
- Variables categóricas: categoría de producto, método de pago, género
- Variable objetivo: Total Purchase Amount

Se detectaron valores nulos en la variable "Returns", los cuales fueron tratados durante la etapa de preprocesamiento.

## 3. Metodología

Se implementó un pipeline de machine learning compuesto por las siguientes etapas:

- Limpieza de datos
- Eliminación de variables irrelevantes
- Tratamiento de valores nulos
- Codificación de variables categóricas
- Escalamiento de variables
- División en conjuntos de entrenamiento y prueba
- Entrenamiento de modelos
- Evaluación mediante métricas
- Validación cruzada
- Optimización de hiperparámetros

## 4. Modelos utilizados

Se entrenaron los siguientes modelos:

- Regresión lineal (modelo base)
- KNN

- KNN optimizado mediante GridSearchCV
- Gradient Boosting

Cada modelo fue evaluado utilizando métricas de regresión.

## 5. Resultados

Se compararon los modelos utilizando MAE, RMSE y  $R^2$ .

Los resultados evidencian que la regresión lineal y el modelo de Gradient Boosting presentan un desempeño similar, con menor error en comparación con KNN.

El modelo KNN, incluso optimizado, presenta un bajo desempeño, con valores de  $R^2$  negativos, lo que indica que no es adecuado para este problema.

En general, todos los modelos presentan un bajo poder explicativo, con valores de  $R^2$  cercanos a 0.

```
In [2]: import pandas as pd

resultados = pd.DataFrame({
    "Modelo": ["Lineal", "KNN", "KNN Optimizado", "Boosting"],
    "MAE": [1245.44, 1331.18, 1292.16, 1245.52],
    "RMSE": [1438.27, 1576.73, 1516.30, 1438.34],
    "R2": [0.00302, -0.19837, -0.10812, 0.00293]
})

resultados
```

```
Out[2]:
```

|   | Modelo         | MAE     | RMSE    | R2       |
|---|----------------|---------|---------|----------|
| 0 | Lineal         | 1245.44 | 1438.27 | 0.00302  |
| 1 | KNN            | 1331.18 | 1576.73 | -0.19837 |
| 2 | KNN Optimizado | 1292.16 | 1516.30 | -0.10812 |
| 3 | Boosting       | 1245.52 | 1438.34 | 0.00293  |


## Visualización de resultados

```
In [3]: import matplotlib.pyplot as plt

resultados.set_index("Modelo")[["MAE", "RMSE", "R2"]].plot(kind="bar")

plt.title("Comparación de modelos")
plt.ylabel("Valor de métricas")
plt.xticks(rotation=45)
plt.tight_layout()
```

```
plt.show()
```



Las visualizaciones permiten comparar de manera clara el desempeño de los modelos.

Se observa que la regresión lineal y el modelo de Gradient Boosting presentan resultados similares, con menores valores de error en comparación con KNN.

Por otro lado, el modelo KNN presenta un desempeño inferior, evidenciado por mayores errores y un coeficiente  $R^2$  negativo.

Esto refuerza la conclusión de que KNN no es adecuado para este problema.

## 6. Conclusión

Se desarrolló un pipeline completo de aprendizaje supervisado, desde la exploración y preparación de datos hasta la evaluación y selección del modelo.

Los resultados muestran que ninguno de los modelos logra capturar adecuadamente la variabilidad del dataset, lo que sugiere una baja relación entre las variables predictoras y la variable objetivo.

Se selecciona la regresión lineal como modelo final por su simplicidad y desempeño comparable con modelos más complejos.

Este resultado resalta la importancia de evaluar críticamente los modelos y no asumir que algoritmos más avanzados siempre generan mejores resultados.